

Univerzitet u Beogradu – Elektrotehnički fakultet

Izvještaj o radu na projektu

Detekcija srčanog ritma iz audio signala

studentkinja: Mihaela Gajić, 21/249, Elektronika i digitalni sistemi

jul 2026. godine

Ovaj izvještaj je rezultat rada na projektu u okviru predmeta Kliničko inženjerstvo (13E054KLIN) koji sam slušala u toku školske 2025/2026. godine na četvrtoj godini osnovnih studija Elektrotehničkog fakulteta kod predmetnog nastavnika dr Nadice Miljković, vanrednog profesora.

Izveštaj sadrži 29 strana, 16 slika i tri tabele. Lista reference uključuje 6 naslova.

Mihaela Gajić

Sadržaj

1 Zadatak projekta.....	4
2 Uvod.....	5
3 Metod rada i materijal	7
3.1 Određivanje broja otkucaja srca u minuti iz EKG signala	7
3.2 Obrada audio signala	9
Mel-frekvencijski kepsralni koeficijenti (MFCC)	10
Energija audio signala (RMS)	11
Zero Crossing Rate	11
Osnovna frekvencija glasa (<i>Pitch</i>)	11
Spektralni centroid	12
3.3 Izvori nesigurnosti rezultata	12
4 Rezultati	13
4.1 Analiza EKG signala	13
4.2 Rezultati obrade audio signala	14
Analiza MFCC koeficijenata u odnosu na srčani ritam	18
5 Diskusija	19
5.1 Analiza rezultata odredjivanja broja otkucaja srca	19
5.2 Analiza izdvojenih audio karakteristika	20
5.3 Povezanost audio karakteristika i broja otkucaja srca	25
5.4 Poređenje sa literaturom	26
5.5 Ograničenja analize	26
6 Zaključak	28
Literatura	29

1 Zadatak projekta

Cilj ovog projekta jeste ispitivanje mogućnosti određivanja srčanog ritma analizom govornog (audio) signala. Tokom eksperimenta istovremeno su snimani elektrokardiografski i audio signal dok je ispitanik govorio unaprijed definisani tekst. Srčani ritam najprije se određuje analizom EKG signala, koji predstavlja referentnu vrijednost za svaki audio zapis. Nakon toga vrši se detaljna analiza audio signala radi izdvajanja akustičkih karakteristika koje bi mogle biti povezane sa promjenama srčanog ritma. Posebna pažnja posvećena je promjenama u govoru koje nastaju usljed različitih emocionalnih stanja, poput ubrzanog ili usporenog tempa govora, promjena visine glasa, intenziteta i drugih spektro-temporalnih karakteristika. Polazi se od pretpostavke da emocionalna stanja utiču istovremeno i na način govora i na rad kardiovaskularnog sistema, zbog čega između govornog signala i srčanog ritma može postojati određena korelacija.

Uspješno utvrđivanje ovakve povezanosti predstavljalo bi značajan korak ka razvoju beskontaktnih sistema za procjenu srčanog ritma, što bi moglo imati široku primjenu u telemedicini, daljinskom praćenju pacijenata, mobilnim zdravstvenim aplikacijama i sistemima za kontinuirani zdravstveni nadzor.

U okviru projekta razmatraju se sljedeća istraživačka pitanja:

- Da li govorni signal sadrži akustičke karakteristike koje su povezane sa srčanim ritmom ispitanika?
- Koje karakteristike audio signala pokazuju najveću povezanost sa promjenama srčanog ritma?
- U kojoj mjeri promjene emocionalnog stanja utiču istovremeno na način govora i na broj otkucaja srca?
- Da li se srčani ritam određen iz EKG signala može koristiti kao pouzdana referenca za analizu odgovarajućih audio zapisa?
- Kolika je mogućnost procjene srčanog ritma isključivo na osnovu karakteristika govornog signala?
- Da li izdvojene karakteristike audio signala predstavljaju dobru osnovu za razvoj beskontaktnih metoda određivanja srčanog ritma u kliničkom inženjerstvu i telemedicini?

2 Uvod

Praćenje vitalnih parametara predstavlja jednu od najvažnijih oblasti kliničkog inženjerstva, jer omogućava pravovremeno otkrivanje promjena u zdravstvenom stanju pacijenta i donošenje odgovarajućih medicinskih odluka. Među vitalnim parametrima posebno se izdvaja srčani ritam, koji predstavlja značajan pokazatelj rada kardiovaskularnog sistema i fiziološkog stanja organizma. Njegovo kontinuirano praćenje ima važnu ulogu u dijagnostici i nadzoru pacijenata sa kardiovaskularnim oboljenjima, ali i u oblastima kao što su telemedicina, kućni monitoring i sistemi za daljinsko praćenje zdravstvenog stanja.

Najpouzdanija metoda za određivanje srčanog ritma jeste analiza elektrokardiografskog (EKG) signala, pri čemu se broj otkucaja srca određuje detekcijom karakterističnih R-vrhova i izračunavanjem vremenskih intervala između uzastopnih otkucaja[1]. Pored EKG-a, u širokoj primjeni nalaze se i metode zasnovane na fotopletizmografiji (PPG), koje koriste optičke senzore za procjenu pulsa. Iako ove metode omogućavaju visoku tačnost i pouzdanost, njihova primjena zahtijeva kontakt senzora sa tijelom korisnika, što može predstavljati ograničenje u brojnim praktičnim situacijama. Dugotrajno nošenje senzora može izazvati nelagodnost kod pacijenata, posebno kod starijih osoba, novorođenčadi i pacijenata sa osjetljivom kožom ili opekotinama. Takođe, kontaktni senzori mogu ograničiti kretanje ispitanika i zahtijevaju pravilno postavljanje i redovno održavanje, što povećava složenost njihove primjene u svakodnevnom životu.

Iz tih razloga, u posljednjih nekoliko godina značajna pažnja posvećena je razvoju beskontaktnih sistema za praćenje vitalnih parametara. Mogućnost određivanja srčanog ritma bez fizičkog kontakta sa pacijentom omogućila bi kontinuirano praćenje zdravstvenog stanja tokom svakodnevnih aktivnosti, u kućnim uslovima ili na udaljenim lokacijama, bez potrebe za prisustvom medicinskog osoblja. Takvi sistemi imaju veliki značaj za razvoj telemedicine, jer omogućavaju daljinsko praćenje hroničnih pacijenata, starijih osoba i osoba koje žive u područjima sa ograničenim pristupom zdravstvenim ustanovama. Pored toga, beskontaktno određivanje srčanog ritma moglo bi biti korisno u situacijama kada upotreba kontaktnih senzora nije moguća ili nije praktična, kao što su hitne intervencije, masovni skrining stanovništva, praćenje pacijenata tokom izolacije, kao i integracija sa mobilnim uređajima i pametnim sistemima za zdravstveni nadzor. Zbog navedenih prednosti, razvoj ovakvih metoda predstavlja jednu od aktuelnih istraživačkih oblasti savremenog kliničkog inženjerstva.

Razvoj savremenih sistema za obradu signala i metoda veštačke inteligencije posljednjih godina otvorio je mogućnost korišćenja alternativnih izvora informacija za procjenu fiziološkog stanja čoveka. Posebna pažnja posvećena je analizi govornog signala, budući da način govora zavisi ne samo od sadržaja koji osoba izgovara, već i od njenog fiziološkog i emocionalnog stanja. Emocije, stres i uzbuđenje mogu izazvati promjene u brzini govora, visini glasa, intenzitetu i spektralnim karakteristikama signala, dok istovremeno utiču i na rad autonomnog nervnog sistema, a samim tim i na srčani ritam. Ovakva povezanost ukazuje na mogućnost da određene karakteristike govora sadrže informacije koje se mogu dovesti u vezu sa brojem otkucaja srca.

U dosadašnjim istraživanjima analizirana je mogućnost određivanja srčanog ritma na osnovu različitih karakteristika govornog signala. Pokazano je da Mel-frekvencijski kepsralni koeficijenti (MFCC), kao jedne od najčešće korišćenih karakteristika u obradi govora, pokazuju

određeni stepen korelacije sa srčanim ritmom određenim iz istovremeno snimljenog EKG signala. U navedenom istraživanju analizirane su promjene MFCC karakteristika govora različitih emocionalnih stanja, pri čemu su rezultati ukazali da određene akustičke karakteristike mogu sadržati informacije povezane sa promjenama srčanog ritma. Međutim, ostvarena tačnost nije bila dovoljna da bi se govor mogao koristiti kao pouzdana zamjena za standardne metode određivanja srčanog ritma. Autori su zaključili da su neophodna dodatna istraživanja sa većim skupovima podataka, naprednijim metodama obrade signala i detaljnijom analizom karakteristika govora kako bi se unaprijedila preciznost ovakvih sistema [2].

Polazeći od rezultata dosadašnjih istraživanja, u ovom projektu primijenjen je pristup zasnovan na istovremenoj analizi EKG i audio signala. EKG signal koristi se za precizno određivanje referentnog srčanog ritma, dok se nad odgovarajućim audio zapisima sprovodi detaljna analiza akustičkih karakteristika sa ciljem ispitivanja njihove povezanosti sa brojem otkucaja srca.

3 Metod rada i materijal

U okviru ovog projekta analizirani su istovremeno snimljeni EKG i audio signali ispitanika tokom čitanja unaprijed definisanog teksta. Cilj mjerenja bio je analiza promjena fizioloških i akustičkih parametara u različitim emocionalnim stanjima ispitanika.

Tokom eksperimenta ispitanik je čitao dva različito definisana teksta, pri čemu je svaki tekst sniman u dva različita stanja: relaksiranom i napetom stanju koje je nastalo kao rezultat fizičke aktivnosti tokom govora. Tokom svakog snimanja istovremeno su bilježeni EKG signal i audio signal govora. Na ovaj način dobijeni su parovi signala koji odgovaraju istom vremenskom intervalu, što omogućava poređenje promjena srčane aktivnosti i karakteristika govora u različitim uslovima.

Materijal korišćen za analizu sastojao se od: tekstualnih datoteka sa zapisanim EKG signalom i audio datoteka sa snimljenim govorom ispitanika,

Za obradu i analizu signala korišćeno je programsko okruženje *Python*. Za učitavanje, obradu i numeričku analizu podataka korišćene su biblioteke:

- *NumPy* za rad sa nizovima podataka, numeričke proračune i manipulaciju signalima,
- *Pandas* za učitavanje i obradu tekstualnih datoteka sa EKG signalom,
- *SciPy* (modul *signal*) za obradu signala i detekciju karakterističnih tačaka u EKG signalu, odnosno R-vrhova,
- *Matplotlib* za grafički prikaz vremenskih oblika signala, izdvojenih karakteristika i dobijenih rezultata,
- *Librosa* za učitavanje, obradu i analizu audio signala, kao i za izdvajanje akustičkih karakteristika govora, kao što su Mel-frekvencijski kepsralni koeficijenti (MFCC), energija signala, nulta stopa prelaska (*Zero Crossing Rate*) i spektralne karakteristike.

EKG signal je analiziran sa ciljem određivanja broja otkucaja srca u minuti, dok je audio signal analiziran kroz parametre govora.

3.1 Određivanje broja otkucaja srca u minuti iz EKG signala

Za određivanje broja otkucaja srca u minuti korišćen je EKG signal iz tekstualne datoteke dobijene tokom mjerenja. Prvi korak obrade predstavlja učitavanje signala i izdvajanje kanala koji sadrži EKG podatke.

Podaci su učitani pomoću biblioteke *Pandas*. Prilikom učitavanja korišćen je tabulator kao razdvajajući znak između kolona ($\backslash t$), dok su linije zaglavlja koje sadrže dodatne informacije o snimanju uklonjene iz analize. Iz učitane matrice izdvojena je treća kolona koja predstavlja izmjereni EKG signal.

Frekvencija odabiranja korišćena u analizi iznosila je: $f_s = 1000 \text{ Hz}$

što znači da je tokom jedne sekunde snimljeno 1000 uzoraka EKG signala. Nakon učitavanja formiran je vremenski vektor koji svakom uzorku pridružuje odgovarajuće vrijeme:

$$t = \frac{n}{f_s}$$

gdje je:

- n redni broj uzorka,
- f_s frekvencija odabiranja.

Prije detekcije otkucaja izvršena je korekcija signala uklanjanjem srednje vrijednosti. Na ovaj način uklonjena je jednosmjerna komponenta signala, odnosno pomjeraj osnovne linije.

Korigovani signal definisan je izrazom:

$$ECG_{corrected} = -1 \cdot (ECG - \overline{ECG})$$

Promjena znaka signala izvršena je kako bi R-vrhovi EKG kompleksa imali pozitivan smjer i bili pogodniji za detekciju.

U ovoj analizi nije primijenjen digitalni filter, jer je kvalitet snimljenog EKG signala bio dovoljan za pouzdanu detekciju R-vrhova. Međutim, u opštem slučaju, prije detekcije srčanog ritma potrebno je primijeniti filtriranje signala.

Najčešće se koristi kombinacija: visokopropusnog filtra za uklanjanje pomijeranja bazne linije i sporih promjena signala, niskopropusnog filtra za uklanjanje visokofrekventnog šuma i notch filtra za uklanjanje smetnji mrežne frekvencije (50 Hz).

Filtar bi bio posebno značajan kod signala sa izraženim šumom, pokretima ispitanika ili lošim kontaktom elektroda, jer bi omogućio precizniju detekciju R-vrhova i smanjio broj pogrešno detektovanih otkucaja.

Za određivanje trenutaka pojave srčanih otkucaja korišćena je funkcija *find_peaks* iz biblioteke *SciPy*.

R-vrhovi predstavljaju najizraženije pozitivne amplitude u EKG signalu i koriste se za određivanje RR intervala. Prilikom detekcije definisana su dva kriterijuma:

1. MINIMALNA VISINA VRHA: $height = \bar{x} + 2000$, čime se odbacuju manje promjene signala koje ne predstavljaju srčane komplekse.

2. MINIMALNO RASTOJANJE IZMEĐU VRHOVA: $distance = 500$, što odgovara minimalnom vremenskom razmaku od $\frac{distance}{f_s} = 0,5$ s između dva uzastopna R-vrha. Na ovaj način spriječena je detekcija više vrhova unutar jednog srčanog kompleksa.

Dobijeni indeksi R-vrhova zatim su korišćeni za izračunavanje RR intervala. Razlika između susjednih R-vrhova predstavlja broj uzoraka između dva otkucaja:

$$\Delta N = R_{i+1} - R_i$$

Pošto je frekvencija odabiranja 1000 Hz, RR interval u sekundama dobija se kao:

$$RR = \frac{\Delta N}{f_s}$$

Trenutni broj otkucaja srca izražen u otkucajima u minuti (*beats per minute - BPM*) izračunat je relacijom:

$$BPM = \frac{60}{RR}$$

Na ovaj način dobijen je niz trenutnih vrijednosti srčanog ritma između svakog uzastopnog para R-vrhova.

Pored pojedinačnih vrijednosti pulsa, izračunate su osnovne statističke karakteristike:

- minimalna vrijednost pulsa,
- maksimalna vrijednost pulsa,
- srednja vrijednost pulsa tokom cijelog snimanja.

Dobijeni rezultati predstavljaju referentni broj otkucaja srca u minuti koji će kasnije biti korišćen za poređenje sa rezultatima analize audio signala i procjenu razlika između relaksiranog i stresnog stanja ispitanika.

3.2 Obrada audio signala

Za analizu audio signala korišćeni su snimci govora ispitanika koji su dobijeni istovremeno sa EKG signalom tokom eksperimenta. Cilj obrade audio signala bio je izdvajanje karakteristika govora koje mogu pokazati razlike između relaksiranog i stresnog stanja ispitanika, kao i njihovo poređenje sa referentnim vrijednostima srčanog ritma dobijenim analizom EKG signala.

Prvi korak obrade predstavlja učitavanje audio datoteke pomoću funkcije:

librosa.load().

Prilikom učitavanja dobijaju se dva osnovna podatka: niz uzoraka audio signala i frekvencija odabiranja signala. Audio signal se predstavlja diskretnim nizom uzoraka:

$$x[n], \quad n = 0, 1, \dots, N - 1$$

gdje je: N broj uzoraka, $x[n]$ amplituda signala u trenutku n .

Na osnovu broja uzoraka i frekvencije odabiranja određeno je trajanje snimljenog govora, a zatim je formiran vremenski vektor koji omogućava prikaz promjene amplitude audio signala u vremenu.

Vremenski vektor određen je relacijom: $t = \frac{n}{f_s}$. Dobijeni vremenski oblik audio signala prikazan je grafički korišćenjem biblioteke *Matplotlib*.

Nakon učitavanja signala izvršeno je izdvajanje karakteristika koje opisuju različite osobine govora. Izabrane karakteristike predstavljaju parametre koji se često koriste u analizi govora i mogu biti povezani sa promjenama izazvanim stresom.

U okviru analize izdvojene su sljedeće karakteristike:

- Mel-frekvencijski kepsralni koeficijenti (MFCC),
- energija audio signala (RMS),
- stopa prelaska kroz nulu (*Zero Crossing Rate*),
- osnovna frekvencija glasa (*Pitch*),
- spektralni centroid.

Mel-frekvencijski kepsralni koeficijenti (MFCC)

MFCC predstavljaju jednu od najčešće korišćenih karakteristika za opis govornog signala. Oni predstavljaju transformaciju spektralnih osobina signala na Mel skalu koja približno odgovara načinu na koji ljudski sluh registruje frekvencije.

Za izdvajanje MFCC karakteristika korišćena je funkcija:

librosa.feature.mfcc()

U analizi je korišćeno 13 MFCC koeficijenata. Dobijena matrica MFCC koeficijenata predstavlja promjenu karakteristika govora kroz vrijeme. Za dalju analizu izračunate su srednje vrijednosti i standardne devijacije svakog koeficijenta:

$$\mu_i = \frac{1}{N} \sum_{n=1}^N MFCC_i(n)$$

$$\sigma_i = \sqrt{\frac{1}{N} \sum_{n=1}^N (MFCC_i(n) - \mu_i)^2}$$

Srednje vrijednosti opisuju dominantne karakteristike govora, dok standardna devijacija pokazuje promjene karakteristika tokom trajanja snimka.

Energija audio signala (RMS)

Za procjenu intenziteta govora izračunata je RMS energija signala.

RMS vrijednost definiše se kao: $RMS = \sqrt{\frac{1}{N} \sum_{n=1}^N x^2(n)}$

Veća RMS vrijednost ukazuje na veću amplitudu odnosno jači govorni signal.

U stresnim situacijama često može doći do promjene intenziteta govora, zbog čega je RMS energija korišćena kao jedna od karakteristika za poređenje različitih stanja ispitanika.

Za računanje RMS energije korišćena je funkcija:

librosa.feature.rms()

Zero Crossing Rate

Zero Crossing Rate predstavlja broj promjena znaka audio signala, odnosno broj prelazaka signala kroz nultu amplitudu.

Definisana je kao:

$$ZCR = \frac{1}{N} \sum_{n=1}^{N-1} |sign(x[n]) - sign(x[n-1])|$$

Ova karakteristika daje informaciju o količini visokofrekventnih komponenti u signalu. Za računanje ZCR korišćena je funkcija:

librosa.feature.zero_crossing_rate()

Promjene ove karakteristike mogu ukazivati na promjene u boji i načinu produkcije glasa.

Osnovna frekvencija glasa (Pitch)

Osnovna frekvencija glasa predstavlja frekvenciju vibracije glasnih žica tokom govora. Za njeno određivanje korišćena je funkcija:

`librosa.yin()`

Nakon izdvajanja pozitivnih vrijednosti frekvencije izračunate su srednja vrednost i standardna devijacija osnovne frekvencije.

Pitch predstavlja značajnu karakteristiku u analizi emocionalnog stanja jer stres može izazvati promjene napetosti glasnih žica i posljedično promjenu visine glasa.

Spektralni centroid

Spektralni centroid predstavlja "težište" spektra audio signala i pokazuje oko koje frekvencije je koncentrisana najveća količina energije.

Izračunava se kao:

$$C = \frac{\sum_k f_k X(k)}{\sum_k X(k)}$$

gdje su:

- f_k frekvencije spektralnih komponenti,
- $X(k)$ amplitudne vrednosti spektra.

Za njegovo određivanje korišćena je funkcija:

`librosa.feature.spectral_centroid()`

Veće vrijednosti centroida ukazuju na prisustvo većeg udjela viših frekvencija u signalu.

3.3 Izvori nesigurnosti rezultata

Dobijene vrijednosti predstavljaju rezultate numeričke obrade prethodno snimljenih signala, a ne direktna ponovljena mjerenja fizičkih veličina. Zbog toga klasična procjena mjerne nesigurnosti zasnovana na ponovljenim mjerenjima nije primijenjena.

Na tačnost dobijenih rezultata mogu uticati:

- kvalitet snimljenih EKG i audio signala,
- prisustvo šuma i artefakata,
- izbor parametara algoritama za obradu signala (prag detekcije R-vrhova, dužina analitičkog prozora, broj MFCC koeficijenata),
- ograničena vremenska rezolucija uslovljena frekvencijom odabiranja.


Tokom analize korišćeni su isti parametri obrade za sve snimke, čime je obezbijedena međusobna uporedivost rezultata.

4 Rezultati

4.1 Analiza EKG signala


Analiza EKG signala izvršena je za sva četiri snimka korišćenjem postupka opisanog u poglavlju 3.1. Kao rezultat obrade dobijeni su korigovani EKG signali, detektovani R-vrhovi i trenutni broj otkucaja srca izražen u otkucajima u minuti (BPM).

Na slici 4.1 prikazan je originalni EKG signal prije izvršene obrade. Na signalu su uočljive karakteristične promjene amplitude koje odgovaraju srčanim ciklusima, kao i prisustvo jednosmjerne komponente zbog koje je bilo neophodno izvršiti korekciju signala prije detekcije R-vrhova.




Slika 4. 1

Na slici 4.2 prikazan je korigovani EKG signal sa označenim R-vrhovima. Nakon uklanjanja srednje vrijednosti i promjene polariteta signala omogućena je pouzdana detekcija R-vrhova. Detektovani vrhovi predstavljaju osnovu za određivanje RR intervala i izračunavanje trenutnog srčanog ritma.



Slika 4. 2

Na osnovu vremenskog rastojanja između uzastopnih R-vrhova određene su vrijednosti trenutnog broja otkucaja srca. Promjena srčanog ritma tokom trajanja snimka prikazana je na slici 4.3.



Slika 4. 3

Za svaki analizirani snimak određene su minimalna, maksimalna i srednja vrijednost broja otkucaja srca. Dobijeni rezultati prikazani su u Tabeli 4.1.

	Minimalni BPM	Maksimalni BPM	Srednji BPM
Zmaj 1 relaxed	96.46	116.05	109.13
Zmaj 1 stres	94.34	114.94	105
Zmaj 2 relaxed	96.93	110.7	105.48
Zmaj 2 stred	101.87	118.58	110.42

Tabela 4. 1


Iz Tabele 4.1 može se uočiti da se vrijednosti broja otkucaja srca razlikuju između analiziranih snimaka, ali ne značajno, što će dalje biti analizirano u poglavlju *Diskusija*. Dobijene srednje vrijednosti predstavljaju referentne vrijednosti koje će u nastavku rada biti korišćene za poređenje sa karakteristikama izdvojenim iz audio signala.

4.2 Rezultati obrade audio signala

Analiza audio signala izvršena je za sva četiri snimka korišćenjem postupka opisanog u poglavlju 3.2. Za svaki audio signal izdvojene su karakteristike koje opisuju različite osobine govora, uključujući Mel-frekvencijske kepralne koeficijente (MFCC), RMS energiju, Zero Crossing Rate (ZCR), osnovnu frekvenciju glasa (Pitch) i spektralni centroid.


Kao primjer postupka obrade, u nastavku su prikazani rezultati dobijeni za snimak *Zmaj 1 – relaxed*, dok je isti postupak primijenjen i na preostala tri audio signala.

Na slici 4.4 prikazan je vremenski oblik audio signala. Na signalu su uočljive promjene amplitude koje odgovaraju izgovoru riječi i pauzama tokom čitanja teksta.




Slika 4. 4

Na slici 4.5 prikazan je spektrogram audio signala kojim je predstavljena raspodjela energije po frekvencijama tokom vremena. Veći intenzitet boje odgovara većoj energiji signala u odgovarajućem frekvencijskom opsegu.




Slika 4. 5

Na slici 4.6 prikazane su MFCC karakteristike izdvojene iz audio signala. Ovi koeficijenti predstavljaju spektralne karakteristike govora i korišćeni su kao jedan od osnovnih parametara za poređenje sa referentnim brojem otkucaja srca.




Slika 4. 6

Na slici 4.7 prikazana je promjena RMS energije tokom trajanja govora. RMS energija opisuje promjenu intenziteta govornog signala.




Slika 4. 7

Na slici 4.8 prikazana je promjena *Zero Crossing Rate (ZCR)* vrijednosti tokom trajanja audio signala. Ova karakteristika predstavlja broj prelazaka signala kroz nultu amplitudu u okviru posmatranog vremenskog prozora i daje informaciju o frekvencijskom sadržaju govora. Veće vrijednosti *ZCR* ukazuju na veći udio visokofrekventnih komponenti u signalu, dok manje vrijednosti odgovaraju dominantno niskofrekventnim komponentama.




Slika 4. 8

Na slici 4.9 prikazana je promjena osnovne frekvencije glasa (*Pitch*) tokom trajanja snimka. Osnovna frekvencija predstavlja frekvenciju vibracije glasnih žica i jedna je od najvažnijih karakteristika govornog signala. Njena promjena može ukazivati na razlike u načinu govora između relaksiranog i stresnog stanja.



Slika 4. 9

Na slici 4.10 prikazana je promjena spektralnog centroida tokom trajanja audio signala. Spektralni centroid predstavlja težište spektra i opisuje raspodjelu energije signala po frekvencijama. Veće vrijednosti centroida ukazuju na prisustvo većeg udjela viših frekvencija u govornom signalu.



Slika 4. 10

Nakon izdvajanja karakteristika iz svih audio signala, dobijene vrijednosti su objedinjene radi poređenja između relaksiranog i stresnog stanja. Za svaki snimak određene su srednje vrijednosti karakteristika audio signala: RMS energije, *Zero Crossing Rate*, osnovne frekvencije glasa (*Pitch*), spektralnog centroida.

Tabela 4.2 prikazuje srednje vrijednosti izdvojenih karakteristika za sva četiri analizirana snimka.

	RMS	ZCR	Pitch[Hz]	SC[Hz]	BPM
Zmaj 1 relaxed	0.036219	0.061629	169.294472	2595.662911	109.13
Zmaj 1 stres	0.030315	0.052382	165.732364	2428.919270	105
Zmaj 2 relaxed	0.036333	0.054147	174.878597	2416.650603	105.48
Zmaj 2 stres	0.031425	0.055521	165.382554	2542.225259	110.42

Tabela 4. 2

Analiza MFCC koeficijenata u odnosu na srčani ritam

MFCC koeficijenti predstavljaju skup numeričkih karakteristika koje opisuju spektralne osobine govornog signala. Za svaki audio snimak izračunate su srednje vrijednosti MFCC koeficijenata, a zatim su one poređene sa referentnim vrijednostima broja otkucaja srca dobijenim analizom EKG signala.

	BPM	MFCC1	MFCC2	MFCC3
Zmaj 1 relaxed	109.13	-398.17288	134.5788	-2.6172953
Zmaj 1 stres	105	-405.11487	135.99075	6.1123509
Zmaj 2 relaxed	105.48	-393.7353	138.22717	-0.8914579
Zmaj 2 stres	110.42	-406.0541	146.50291	-6.0822477

Tabela 4. 3

5 Diskusija


5.1 Analiza rezultata određivanja broja otkucaja srca


Na osnovu rezultata prikazanih u poglavlju 4 može se uočiti da između snimaka nastalih u relaksiranom i stresnom stanju nisu zabilježene izražene razlike u srednjem broju otkucaja srca. Dobijene vrijednosti BPM razlikuju se svega nekoliko otkucaja u minuti, zbog čega se na osnovu srednjih vrijednosti ne može zaključiti da je fizička aktivnost dovela do značajnog povećanja srčanog ritma.

Ovakav rezultat nije u potpunosti u skladu sa očekivanjima, budući da se tokom fizičke aktivnosti ili izlaganja stresu obično očekuje povećanje broja otkucaja srca usljed pojačane aktivnosti simpatičkog nervnog sistema. Međutim, na dobijene rezultate mogli su uticati i drugi faktori, poput emocionalnog stanja ispitanika tokom mjerenja, uključujući nervozu, uzbuđenje ili strah, koji mogu izazvati promjene srčanog ritma nezavisno od fizičke aktivnosti.

Iako srednje vrijednosti BPM ne pokazuju izražene razlike između relaksiranog i stresnog stanja, detaljnijom analizom grafika trenutnog broja otkucaja srca mogu se uočiti određene promjene tokom trajanja snimanja. Kod snimka *Zmaj 1 – relaxed* broj otkucaja srca je na početku mjerenja nešto veći, nakon čega se postepeno stabilizuje. Takvo ponašanje može ukazivati na početnu emocionalnu reakciju ispitanika na početak eksperimenta, nakon čega dolazi do prilagođavanja uslovima mjerenja.

Sa druge strane, kod snimka *Zmaj 1 – stres* izraženije povećanje broja otkucaja srca javlja se tek nakon određenog vremena od početka snimanja. Takav rezultat može biti posljedica činjenice da je organizmu potrebno nekoliko sekundi da se fiziološke promjene ispolje kroz povećanje srčanog ritma. Zbog toga se najveće vrijednosti BPM ne moraju pojaviti odmah na početku snimanja, već nakon kraćeg vremenskog intervala.






Slika 5. 1 Poređenje trenutnog broja otkucaja srca u snimku Zmaj 1 relaxed i Zmaj 1 stres

Na osnovu prikazanih rezultata može se zaključiti da analiza trenutnog broja otkucaja srca pruža više informacija o promjenama fiziološkog stanja ispitanika nego poređenje isključivo srednjih vrednosti BPM.

5.2 Analiza izdvojenih audio karakteristika




Slika 5. 2

Slika 5.2 prikazuje poređenje srednjih vrijednosti RMS energije za sva četiri analizirana audio snimka. RMS energija predstavlja mjeru prosječne energije signala i često se koristi za procjenu intenziteta govora. Veće vrijednosti RMS energije ukazuju na glasniji i energetski bogatiji signal, dok manje vrijednosti odgovaraju govoru manjeg intenziteta.

Na osnovu prikazanih rezultata može se uočiti da RMS energija ima niže vrijednosti u stresnom stanju u odnosu na relaksirano stanje za oba primjera. Kod uzorka Zmaj 1, RMS energija opala je


sa približno 0,036 na 0,030, dok je kod ispitanika Zmaj 2 zabilježen pad sa oko 0,036 na 0,031. Iako razlike nisu velike, isti trend prisutan je kod oba ispitanika, što može ukazivati na promjenu intenziteta govora tokom stresnog stanja. Međutim, imajući u vidu mali broj analiziranih uzoraka, nije moguće zaključiti da je ovakav trend univerzalan.



Slika 5. 3

Na Slici 5.3 prikazane su srednje vrijednosti osnovne frekvencije glasa (*Pitch*) za sva četiri analizirana audio snimka. Pitch predstavlja osnovnu frekvenciju vibracije glasnih žica i jedan je od najčešće korišćenih parametara u analizi govora.


Dobijeni rezultati pokazuju da je kod oba ispitanika srednja vrijednost *Pitch-a* nešto niža u stresnom stanju nego u relaksiranom. Kod uzorka Zmaj 1 srednja osnovna frekvencija smanjena je sa približno 169 Hz na 166 Hz, dok je kod uzorka Zmaj 2 zabilježen pad sa oko 175 Hz na 165 Hz. Iako literatura često navodi da stres može izazvati povećanje osnovne frekvencije glasa, poznato je da promjena *Pitch-a* zavisi od vrste stresa, individualnih karakteristika govornika i načina govora. Zbog toga dobijeni rezultati ne predstavljaju odstupanje, već potvrđuju da Pitch sam po sebi nije dovoljan pokazatelj fiziološkog stanja.



Slika 5. 4

Spektralni centroid predstavlja mjeru raspodjele energije u frekvencijskom domenu i često se opisuje kao „centar mase“ spektra audio signala. Veće vrijednosti spektralnog centroida ukazuju na veću zastupljenost viših frekvencija u signalu.


Za razliku od RMS energije i Pitch-a, spektralni centroid ne pokazuje isti trend kod oba uzorka. Kod uzorka Zmaj 1 centroid se smanjuje u stresnom stanju, dok kod uzorka Zmaj 2 dolazi do njegovog povećanja. Ovakav rezultat ukazuje da raspodjela energije po frekvencijama zavisi od individualnog načina govora i da nije direktno povezana sa promjenom broja otkucaja srca. Iz tog razloga spektralni centroid treba posmatrati zajedno sa ostalim govornim karakteristikama.



Slika 5. 5

Na Slici 5.5 prikazane su srednje vrijednosti *Zero Crossing Rate* (*ZCR*) za sva četiri analizirana audio snimka. Ova karakteristika predstavlja broj promjene znaka signala u jedinici vremena i daje informaciju o frekvencijskom sadržaju govora. Veće vrijednosti *ZCR* najčešće ukazuju na prisustvo većeg broja visokofrekventnih komponenti ili bezvučnih glasova.

Dobijeni rezultati pokazuju da između relaksiranog i stresnog stanja ne postoji jedinstven trend promene *ZCR*. Kod uzorka Zmaj 1 uočava se smanjenje srednje vrijednosti *ZCR* u stresnom stanju, dok je kod ispitanika Zmaj 2 zabilježeno blago povećanje. To ukazuje da *ZCR* više zavisi od načina izgovora i fonetskog sadržaja govora nego od samog fiziološkog stanja ispitanika.



Slika 5. 6

Na Slici 5.6 prikazane su srednje vrijednosti prva tri MFCC koeficijenta za sva četiri analizirana audio snimka. MFCC koeficijenti predstavljaju jednu od najvažnijih karakteristika govornog signala, jer opisuju njegov spektralni oblik na način sličan ljudskoj percepciji zvuka.

Može se uočiti da prvi MFCC koeficijent ima niže vrijednosti u stresnom stanju kod oba uzorka. Kod Zmaj 1 srednja vrijednost smanjena je sa približno -398 na -405 , dok je kod uzorka Zmaj 2 promjena iznosila od oko -394 do -406 . Ovakav trend ukazuje da stres utiče na ukupnu raspodjelu energije u spektru govora.

Drugi MFCC koeficijent pokazuje povećanje u stresnom stanju kod oba uzorka, pri čemu je izraženija promjena uočena kod uzorka Zmaj 2. Nasuprot tome, treći MFCC koeficijent ne pokazuje jedinstven trend, već se njegov smjer promjene razlikuje između dva ispitanika. To potvrđuje da pojedinačni MFCC koeficijenti ne predstavljaju direktne pokazatelje fiziološkog stanja, već da njihova interpretacija zahtijeva zajedničku analizu većeg broja koeficijenata.

Rezultati ukazuju da su upravo MFCC koeficijenti pokazali najveću osjetljivost na promjene između relaksiranog i stresnog stanja u odnosu na ostale analizirane karakteristike audio signala. Zbog toga se MFCC karakteristike često koriste kao ulazni parametri u sistemima za automatsko

prepoznavanje emocija, detekciju stresa i procjenu fiziološkog stanja primjenom metoda mašinskog učenja.

5.3 Povezanost audio karakteristika i broja otkucaja srca

Jedan od osnovnih ciljeva ovog rada bio je ispitati da li postoji povezanost između karakteristika govornog signala i referentnog broja otkucaja srca određenog iz EKG signala. Kao referentna vrijednost korišćen je srednji broj otkucaja srca (BPM), dok su za opis audio signala izdvojene karakteristike RMS energija, *Zero Crossing Rate (ZCR)*, osnovna frekvencija glasa (*Pitch*), spektralni centroid (SC) i MFCC koeficijenti.

Poređenjem dobijenih rezultata može se uočiti da nije zabilježena jednoznačna zavisnost između srednje vrijednosti BPM i analiziranih audio karakteristika. Kod uzorka Zmaj 1 stresno stanje bilo je praćeno blagim smanjenjem srednje vrijednosti broja otkucaja srca, dok je kod uzorka Zmaj 2 u stresnom stanju zabilježen porast BPM. Slična neujednačenost uočena je i kod pojedinih audio karakteristika, što ukazuje da njihov odnos sa srčanim ritmom nije linearan.

Kod RMS energije i *Pitch-a* uočena je slična tendencija kod oba ispitanika, odnosno njihove srednje vrijednosti bile su nešto niže u stresnom stanju u odnosu na relaksirano stanje. Međutim, ove promjene nisu bile praćene istim promjenama broja otkucaja srca. To ukazuje da promjene intenziteta i osnovne frekvencije govora ne zavise isključivo od srčanog ritma, već i od drugih faktora, poput načina govora, disanja, emocionalnog stanja i individualnih karakteristika ispitanika.

Najizraženije promjene uočene su kod MFCC koeficijenata. Prvi MFCC koeficijent imao je niže vrijednosti u stresnom stanju kod oba ispitanika, dok je drugi MFCC koeficijent pokazao blago povećanje. Treći MFCC koeficijent pokazao je različit smjer promjene kod dva uzorka, što ukazuje da spektralne karakteristike govora reaguju na promjene fiziološkog stanja, ali da način njihove promjene nije univerzalan.

Dobijeni rezultati pokazuju da pojedinačne audio karakteristike mogu ukazivati na određene promjene fiziološkog stanja, ali da na osnovu malog broja analiziranih snimaka nije moguće uspostaviti pouzdan matematički model koji bi direktno povezivao vrijednosti audio karakteristika sa brojem otkucaja srca. Za pouzdaniju procjenu bilo bi potrebno analizirati veći broj ispitanika i koristiti veći skup govornih uzoraka različitog trajanja i intenziteta stresa.

Na osnovu sprovedene analize može se zaključiti da se najveći potencijal za procjenu fiziološkog stanja iz govora u ovom radu pokazao kod MFCC koeficijenata, budući da su oni dosljedno registrovali promjene između relaksiranog i stresnog stanja kod oba ispitanika. Ipak, njihova promjena nije pratila promjenu broja otkucaja srca na jednoznačan način, što ukazuje da je za pouzdanu procjenu srčanog ritma iz audio signala potrebno istovremeno analizirati veći broj govornih karakteristika i primijeniti odgovarajuće modele mašinskog učenja.

5.4 Poređenje sa literaturom

Dobijeni rezultati mogu se uporediti sa istraživanjima koja se bave analizom govora kao neinvazivnim pokazateljem fiziološkog i emocionalnog stanja čoveka. Brojna istraživanja potvrđuju da stres izaziva promjene u govornom signalu usled aktivacije autonomnog nervnog sistema, pri čemu dolazi do promjena srčanog ritma, disanja, napetosti glasnih žica i načina fonacije. Ove fiziološke promjene odražavaju se na različite akustičke karakteristike govora.

Sličan zaključak navodi se i u preglednim radovima iz oblasti analize govora, gde se MFCC izdvajaju kao jedne od najznačajnijih karakteristika za opis spektralnog sadržaja govora i detekciju emocionalnih i stresnih stanja.

U literaturi se navodi da promjene osnovne frekvencije glasa pod uticajem stresa nisu jednoznačne. Dok pojedina istraživanja pokazuju porast srednje vrijednosti osnovne frekvencije tokom stresnih zadataka, druga ukazuju da smjer promene zavisi od vrste izazvanog stresa, individualnih karakteristika govornika i eksperimentalnih uslova.

Kada je u pitanju povezanost govornih karakteristika i broja otkucaja srca, rezultati ovog rada pokazali su da nije moguće uspostaviti jednostavnu linearnu zavisnost između srednje vrijednosti BPM i pojedinačnih audio karakteristika. Sličan zaključak navodi se i u savremenim istraživanjima, u kojima se ističe da procjena fizioloških parametara iz govora zahtijeva istovremenu analizu većeg broja akustičkih karakteristika i primjenu algoritama mašinskog učenja.[3][4][5][6]

5.5 Ograničenja analize

Razlike između rezultata prikazanih u ovom radu i pojedinih rezultata iz literature mogu se objasniti ograničenim brojem analiziranih snimaka, malim brojem ispitanika i činjenicom da su analizirana samo dva govorna zadatka.

Dodatno ograničenje predstavlja činjenica da reakcija na stres nije ista kod svih osoba. Individualne razlike u emocionalnom odgovoru, načinu govora, brzini čitanja, jačini glasa i fiziološkoj reakciji mogu značajno uticati na analizirane karakteristike. Zbog toga promjene u audio signalu ne moraju biti direktna posljedica promjene broja otkucaja srca, već mogu nastati i usljed drugih faktora povezanih sa trenutnim stanjem ispitanika.

Na rezultate analize mogle su uticati i karakteristike samog eksperimenta. Ispitanik je čitao unaprijed definisan tekst, što ograničava prirodnost govora i može dovesti do promjena u intonaciji, ritmu i načinu izgovora koje nisu isključivo posljedica stresnog stanja. Takođe, nije bilo moguće potpuno kontrolisati sve spoljašnje faktore, kao što su položaj ispitanika tokom snimanja, udaljenost od mikrofona i eventualni šum iz okruženja.

Još jedno ograničenje predstavlja način poređenja rezultata. U radu su analizirane srednje vrijednosti izdvojenih audio karakteristika i srednja vrijednost broja otkucaja srca, dok su

promjene tokom vremena razmatrane samo na pojedinačnim grafikonima. Za detaljniju analizu bilo bi korisno posmatrati vremensku zavisnost između promjena audio karakteristika i promjena BPM vrijednosti, kao i primijeniti statističke metode za procjenu njihove međusobne povezanosti.

Uprkos navedenim ograničenjima, sprovedena analiza pokazuje da govorni signal sadrži karakteristike koje se mogu povezati sa promjenama fiziološkog stanja i predstavlja dobru osnovu za dalja istraživanja u oblasti neinvazivne procjene stresa i srčanog ritma.

6 Zaključak

U ovom radu izvršena je analiza EKG i audio signala sa ciljem ispitivanja povezanosti karakteristika govora sa fiziološkim stanjem ispitanika. Na osnovu EKG signala određen je referentni broj otkucaja srca, dok su iz audio signala izdvojene karakteristike RMS energije, *Zero Crossing Rate*, *Pitch*, spektralni centroid i MFCC koeficijenti.

Rezultati su pokazali da između relaksiranog i stresnog stanja ne postoji izražena razlika u srednjim vrijednostima BPM, ali su uočene promjene tokom vremena koje mogu biti povezane sa fiziološkim i emocionalnim stanjem ispitanika. Audio analiza je pokazala da se pojedine govorne karakteristike mijenjaju između različitih stanja, pri čemu su najznačajnije promjene uočene kod MFCC koeficijenata.

Ipak, nije utvrđena jednoznačna veza između pojedinačnih audio karakteristika i broja otkucaja srca. Za pouzdaniju procjenu fizioloških parametara iz govornog signala potrebno je analizirati veći broj ispitanika, koristiti više karakteristika i primijeniti naprednije metode obrade podataka.

Dobijeni rezultati predstavljaju osnovu za dalji razvoj neinvazivnih metoda procjene fiziološkog stanja na osnovu audio signala.

Literatura

1. J. Pan and W. J. Tompkins, *A Real-Time QRS Detection Algorithm*, IEEE Transactions on Biomedical Engineering, 1985.
2. P. James, *Heart Rate Monitoring Using Human Speech Spectral Features*, *Human-Centric Computing and Information Sciences*, Vol. 5, Article 33, 2015.
3. R. M. Bermúdez de Alvear, F. J. Barón-López, M. D. Alguacil and M. S. Dawid-Milner, *Interactions between Voice Fundamental Frequency and Cardiovascular Parameters: Preliminary Results and Physiological Mechanisms*, *Logopedics Phoniatrics Vocology*, vol. 38, no. 2, pp. 52–58, 2013.
4. A. Baird *et al.*, *An Evaluation of Speech-Based Recognition of Emotional and Physiological Markers of Stress*, *Frontiers in Computer Science*, vol. 3, 2021.
5. *Measuring Negative Emotions and Stress Through Acoustic Correlates in Speech: A Systematic Review*, PLOS ONE, 2025.
6. A. Ryskaliyev, S. Askaruly and A. P. James, *Speech Signal Analysis for the Estimation of Heart Rates Under Different Emotional States*, 2016.